



StressGuard

LAPORAN TEKNIS KOMPREHENSIF

Deteksi Dini Tingkat Stres Berdasarkan Pola Tidur dan Penggunaan Mobile

Coding Camp 2026 powered by DBS Foundation

Tema: Healthy Lives & Well-being

Tim Pengembang:

Dimas Bangkit Sanjaya | Izzah Huwaidah | Muhammad Enuh | M. I. S. Pratama

SourceDataset: Kaggle - Sleep, Screen Time & Stress Analysis

DAFTAR ISI

1. Problem Discovery & Solusi Utama.....	3
1.1 Latar Belakang Masalah	3
1.2 Pertanyaan Utama.....	3
1.3 Solusi yang Dikembangkan	3
2. Data Gathering.....	4
Alasan Pemilihan Dataset:	4
3. Data Wrangling.....	5
3.1 Assessing Data.....	5
3.2 Cleaning Data	5
4. Pertanyaan Bisnis Terukur.....	5
5. Exploratory Data Analysis (EDA).....	6
5.1 Distribusi Target.....	6
5.2 Temuan Utama EDA	6
6. Feature Engineering.....	7
7. Dataset Siap Model & Data Dictionary	7
7.1 Fitur yang Dipilih untuk Deployment	7
7.2 Preprocessing Pipeline.....	8
7.3 Baseline Model - Random Forest	8
8. Dashboard Streamlit.....	8
Cara Menjalankan (Lokal):.....	10
9. A/B Testing	10
9.1. Desain Eksperimen:	10
9.2. Uji Statistik yang Digunakan:.....	11
9.3. Hasil Simulasi A/B Test:	11
10. Deployment ke Streamlit Cloud.....	12
Isi requirements.txt:	13
11. Kesimpulan & Rekomendasi Akhir	13
11.1 Kesimpulan.....	13
11.2 Rekomendasi Bisnis per Segmen	13
11.3 Pengembangan Lanjutan.....	14

1. Problem Discovery & Solusi Utama

1.1 Latar Belakang Masalah

Kesehatan mental, khususnya stres, merupakan isu global yang semakin meningkat terutama di kalangan mahasiswa dan pekerja muda. Banyak individu yang masih tidak menyadari bahwa penggunaan ponsel berlebihan sebelum tidur dan pola tidur yang tidak teratur merupakan sinyal peringatan dini stres kronis. Oleh karena itu, banyak kasus stres sulit dideteksi lebih awal karena minimnya kesadaran terkait sinyal awal seseorang mengalami stres. Stres yang tidak ditangani berkepanjangan dapat menurunkan kualitas pekerjaan seseorang ataupun menimbulkan demotivasi dalam menjalani hidup. Sehingga, sistem deteksi dini stres ini sangat berguna dan sedang banyak dikembangkan dengan berbagai cara. Salah satu perkembangan dari sistem ini yaitu menerapkan machine learning dan artificial intelligence dalam membantu mendeteksi stres dari pola hidup sehari-hari dan demografi seseorang.

Urgensi pengembangan sistem deteksi dini stres juga diperkuat oleh kondisi kesehatan mental global yang semakin serius. Santomauro et al. (2021) melaporkan bahwa pandemi COVID-19 berkontribusi terhadap peningkatan beban gangguan depresi dan kecemasan secara global, sehingga menunjukkan bahwa masalah kesehatan mental dapat meningkat secara luas ketika individu menghadapi tekanan sosial, akademik, pekerjaan, maupun perubahan pola hidup. Selain itu, Sohn et al. (2019) melalui *systematic review* dan *meta-analysis* menemukan bahwa *problematic smartphone use* pada anak muda berkaitan dengan peningkatan risiko depresi, kecemasan, stres, dan kualitas tidur yang buruk. Temuan tersebut menunjukkan bahwa kebiasaan digital dan kualitas tidur bukan hanya isu gaya hidup, tetapi juga dapat menjadi sinyal awal yang relevan untuk memantau risiko stres. Berdasarkan latar belakang tersebut, problem utama yang ingin dijawab dalam proyek ini adalah: apakah pola penggunaan ponsel dan kualitas tidur dapat digunakan sebagai indikator untuk mendeteksi tingkat stres pengguna secara lebih dini?

1.2 Pertanyaan Utama

Apakah pola penggunaan ponsel dan kualitas tidur dapat digunakan sebagai prediktor tingkat stres yang akurat?

1.3 Solusi yang Dikembangkan

Solusi yang dikembangkan dalam proyek ini adalah sistem deteksi dini tingkat stres berbasis data yang menganalisis pola tidur harian, penggunaan ponsel, screen time, dan beberapa informasi dasar pengguna. Sistem ini dirancang sebagai alat bantu awal untuk mengidentifikasi risiko stres pengguna secara lebih cepat, sehingga pengguna dapat memperoleh gambaran kondisi stresnya serta rekomendasi sederhana yang bersifat pencegahan untuk membantu menjaga pola hidup dan kesehatan mental.

Dalam implementasinya, sistem mengklasifikasikan tingkat stres pengguna ke dalam tiga kategori, yaitu Low, Medium, dan High. Selain menghasilkan kategori stres, sistem juga memberikan rekomendasi personal berdasarkan pola risiko pengguna, seperti pengurangan screen time, perbaikan kualitas tidur, pengaturan penggunaan ponsel sebelum tidur, serta monitoring kebiasaan harian. Dengan demikian,

solusi ini tidak hanya berfokus pada prediksi, tetapi juga mendukung peningkatan kesadaran pengguna terhadap hubungan antara pola hidup dan kesehatan mental.

Komponen	Deskripsi
Input Utama	Usia, jenis kelamin, durasi tidur, kualitas tidur, screen time harian, dan penggunaan HP sebelum tidur
Proses Data Science	Data cleaning, feature engineering, EDA, analisis korelasi, segmentasi risiko, dan data dictionary
Model AI/ML	Model klasifikasi untuk memprediksi kategori stres Low, Medium, dan High berdasarkan fitur input pengguna dengan Tensorflow.
Output	Kategori stres (Low / Medium / High) + rekomendasi personal
Dashboard	Dashboard Streamlit untuk menampilkan insight EDA, distribusi stres, segmentasi pengguna, dan rekomendasi bisnis
Teknologi	Python, Scikit-learn (<i>Random Forest</i> untuk menentukan <i>feature importance</i>), Streamlit, Pandas, Seaborn, serta integrasi aplikasi web.
Dataset	Kaggle - <i>Sleep, Screen Time & Stress Analysis</i> (15.000 baris)
Output	Kategori stres (Low / Medium / High) + rekomendasi personal

2. Data Gathering

Dataset diperoleh dari platform Kaggle dengan judul *Sleep, Screen Time and Stress Analysis*. Dataset berisi 15.000 baris data sintetis yang mencerminkan pola tidur, penggunaan mobile, kelelahan mental, dan tingkat stres pengguna.

Atribut	Detail
Sumber	Kaggle (jayjoshi37)
Nama File	sleep_mobile_stress_dataset_15000.csv
Ukuran	15.000 baris x 13 kolom
Jenis Data	Data sintetis bertema sleep & mobile stress detection
Akses	CSV publik via GitHub raw URL / Kaggle download

Alasan Pemilihan Dataset:

- Memiliki variabel pola tidur (durasi, kualitas) yang relevan dengan solusi.
- Terdapat variabel screen time dan penggunaan HP sebelum tidur sebagai prediktor utama.
- Kolom stress_level tersedia sebagai variabel target klasifikasi.
- Data cukup besar (15.000 baris) untuk pelatihan model yang andal.

3. Data Wrangling

3.1 Assessing Data

Sebelum analisis, dilakukan pemeriksaan kualitas data secara menyeluruh meliputi struktur data, missing values, duplikasi, statistik deskriptif, dan deteksi outlier dengan metode IQR.

Aspek	Temuan
Ukuran Data	15.000 baris x 13 kolom
Missing Values	0 (tidak ada)
Data Duplikat	0 (tidak ada)
Tipe Kolom	11 numerik, 2 kategorikal (gender, occupation)
Outlier (Deteksi dengan metode IQR)	9 baris pada kolom sleep_quality_score (0,06% - tetap dipertahankan)
Rentang Usia	18-59 tahun
Stress Level	Skala numerik 1-10 (perlu konversi ke kategori Low/Medium/High)

3.2 Cleaning Data

Proses pembersihan data mencakup standarisasi nama kolom, penghapusan kolom ID yang tidak diperlukan untuk modeling, serta validasi ulang outlier dengan ringkasan hasil pembersihan data yang telah dilakukan sebagai berikut:

- Rename kolom: sleep_duration_hours -> sleep_hours untuk konsistensi pipeline.
- Kolom user_id dihapus karena bukan fitur model.
- Drop duplicates: tidak ada duplikasi, dataset tetap 15.000 baris.
- Imputasi: tidak diperlukan karena tidak ada missing value.
- Outlier sleep_quality_score (9 baris) dipertahankan karena nilai masih valid secara domain.

4. Pertanyaan Bisnis Terukur

Pertanyaan bisnis pada bagian ini digunakan sebagai dasar dalam menentukan arah analisis dan evaluasi hasil proyek. Melalui pertanyaan ini, proses EDA, feature engineering, dan pemodelan diarahkan untuk menjawab kebutuhan utama sistem, yaitu memahami hubungan antara pola tidur, penggunaan mobile, dan tingkat stres pengguna. Dengan adanya pertanyaan bisnis yang terukur, hasil analisis dapat diterjemahkan menjadi insight dan rekomendasi yang lebih jelas bagi pengembangan aplikasi StressGuard. Pertanyaan bisnis yang kami rumuskan sebagai berikut:

Kode	Pertanyaan Bisnis
BQ-1	Faktor apa saja yang paling berkaitan dengan tingkat stres pengguna?
BQ-2	Apakah screen time harian dan penggunaan ponsel sebelum tidur berkaitan dengan tingkat stres yang lebih tinggi?



BQ-3	Apakah kualitas tidur dapat membedakan kategori stres rendah, sedang, dan tinggi?
BQ-4	Kombinasi pola perilaku apa yang menunjukkan risiko stres tinggi?
BQ-5	Segmen pengguna mana yang perlu diprioritaskan untuk intervensi atau rekomendasi produk?

Metrik Utama: Distribusi stress_category, rata-rata stress_level, korelasi fitur numerik, Mutual Information, feature importance model Random Forest, dan high stress rate per segmen.

5. Exploratory Data Analysis (EDA)

5.1 Distribusi Target

Variabel target stress_level (skala 1-10) dikonversi ke tiga kategori: Low (1-3.99), Medium (4-6.99), dan High (7-10). Distribusi relatif seimbang dengan sedikit dominasi kategori Medium.



Kategori	Estimasi Jumlah	Proporsi
Low (1-3.99)	~2720 data	~18.1%
Medium (4-6.99)	~4190 data	~27.9%
High (7-10)	~8090 baris	~53.9%

5.2 Temuan Utama EDA

- BQ-1 - Faktor terkuat: mental_fatigue_score, daily_screen_time_hours, dan sleep_quality_score memiliki korelasi tertinggi terhadap stress_level.
- BQ-2 - Screen time & HP sebelum tidur: Pengguna dengan screen time > 7 jam/hari memiliki rata-rata stress_level jauh lebih tinggi. Penggunaan HP > 60 menit sebelum tidur berkorelasi positif dengan stres.

- BQ-3 - Kualitas tidur: Distribusi sleep_quality_score berbeda signifikan antara kategori Low, Medium, dan High stress (uji Kruskal-Wallis, $p < 0.01$).
- BQ-4 - Kombinasi berisiko: Kombinasi screen time tinggi + kualitas tidur rendah merupakan pola perilaku dengan high stress rate tertinggi (100%).
- BQ-5 - Segmen prioritas: Segmen high_screen_low_sleep_quality (2.889 pengguna) adalah segmen paling kritis.

6. Feature Engineering

Fitur turunan dibuat dari konteks domain untuk meningkatkan kekuatan prediktif model.

Fitur Baru	Deskripsi
stress_category	Konversi stress_level (1-10) ke Low/Medium/High
sleep_duration_category	Kategori durasi tidur: short (<6j) / ideal (6-8j) / long (>8j)
sleep_quality_category	Kategori kualitas tidur: poor / average / good
phone_usage_before_sleep_category	Kategori penggunaan HP: low / moderate / high
daily_screen_time_category	Kategori screen time: low / moderate / high
sleep_deficit_hours	Kekurangan tidur dari 7 jam ($\max(0, 7 - \text{sleep_hours})$)
poor_quality_and_short_sleep	Bernilai 1 jika kualitas tidur poor dan tidur < 6 jam
high_phone_usage_low_sleep	Bernilai 1 jika penggunaan HP tinggi dan tidur < 6 jam
high_screen_high_fatigue	Bernilai 1 jika screen time tinggi dan mental fatigue tinggi
notification_intensity_per_hour	Rata-rata notifikasi per jam tidur
priority_segment	Segmen risiko: high_screen_low_sleep_quality / high_screen_time / low_sleep_quality / general_users

7. Dataset Siap Model & Data Dictionary

7.1 Fitur yang Dipilih untuk Deployment

Fitur dipilih berdasarkan ketersediaan sebagai input user pada aplikasi. Mental_fatigue_score yang sangat informatif tidak dimasukkan ke model deployment karena tidak tersedia sebagai input user secara langsung.

Fitur	Tipe	Keterangan
age	Numerik	Usia pengguna
sleep_hours	Numerik	Durasi tidur (jam)
sleep_quality_score	Numerik	Skor kualitas tidur 1-10

sleep_quality_category	Kategorikal	Kategori kualitas tidur
daily_screen_time_hours	Numerik	Screen time harian (jam)
phone_usage_before_sleep_minutes	Numerik	Menit penggunaan HP sebelum tidur
phone_usage_before_sleep_category	Kategorikal	Kategori penggunaan HP
poor_quality_and_short_sleep	Biner	Flag interaksi
high_phone_usage_low_sleep	Biner	Flag interaksi
occupation	Kategorikal	Pekerjaan pengguna
gender	Kategorikal	Jenis kelamin

7.2 Preprocessing Pipeline

- Fitur numerik: SimpleImputer (median) -> StandardScaler.
- Fitur kategorikal: SimpleImputer (most_frequent) -> OneHotEncoder (handle_unknown='ignore').
- ColumnTransformer menggabungkan dua pipeline di atas.
- Target stress_category di-encode dengan LabelEncoder: High=0, Low=1, Medium=2.
- Split train-test: 80/20 stratified berdasarkan target.








7.3 Baseline Model - Random Forest


Model baseline Random Forest digunakan sebagai referensi performa awal sebelum tuning lanjutan dilakukan oleh tim AI Engineer menggunakan deep learning dan baseline model ini digunakan untuk menentukan feature importance dari tabel fitur yang paling berpengaruh terhadap target diaats.

Parameter / Metrik	Nilai
n_estimators	200
class_weight	balanced
random_state	42
n_jobs	-1 (all cores)
Accuracy (est.)	~0.90+
F1 Macro (est.)	~0.89+

8. Dashboard Streamlit

Dashboard interaktif dibangun menggunakan Streamlit untuk menampilkan insight, segmentasi pengguna, prediksi stres, dan rekomendasi bisnis kepada stakeholder secara visual.





Tab / Fitur	Deskripsi
Ringkasan	Metrik utama: jumlah pengguna, high stress rate, rata-rata tidur & screen time. Heatmap korelasi.
EDA	Boxplot & violin plot distribusi stres per fitur utama. Bar chart stres per pekerjaan.
Segmentasi	Tabel & visualisasi high stress rate per segmen risiko beserta rekomendasi intervensi.
Screening	Form input user -> estimasi skor stres + kategori + rekomendasi personal berbasis rule EDA.
Insight & Rekomendasi	Ringkasan temuan kunci, tabel rekomendasi produk per segmen, dan data dictionary.

Cara Menjalankan (Lokal):

`pip install streamlit pandas numpy matplotlib seaborn scipy scikit-learn`

`streamlit run dashboard.py`

9. A/B Testing

A/B Testing dilakukan untuk mengevaluasi efektivitas intervensi rekomendasi berbasis segmen risiko stres terhadap penurunan tingkat stres pengguna. Dalam konteks proyek StressGuard, intervensi yang diuji adalah rekomendasi personal yang diberikan kepada pengguna berdasarkan segmen risiko, seperti rekomendasi pengurangan screen time, perbaikan kualitas tidur, dan pengaturan penggunaan HP sebelum tidur.

Pada tahap ini, A/B Testing dilakukan menggunakan data simulasi karena aplikasi belum memiliki data eksperimen dari pengguna asli. Simulasi ini tetap berguna sebagai rancangan evaluasi untuk menunjukkan bagaimana efektivitas rekomendasi dapat diukur apabila aplikasi sudah digunakan secara langsung oleh pengguna.

9.1. Desain Eksperimen:

Eksperimen dibagi menjadi dua kelompok, yaitu kelompok kontrol dan kelompok treatment. Kelompok kontrol tidak menerima rekomendasi khusus, sedangkan kelompok treatment menerima rekomendasi

personal berbasis segmen risiko stres. Kedua kelompok dibandingkan berdasarkan tingkat stres setelah periode simulasi selama 14 hari

Aspek	Detail
Grup A - Kontrol	500 pengguna tidak mendapat intervensi apapun
Grup B - Treatment	500 pengguna mendapat rekomendasi personal berbasis segmen risiko
Durasi Simulasi	14 hari (data pre/post disimulasikan)
Metrik Utama	Rata-rata stress_level post-test, proporsi penurunan kategori stres

Pre-test digunakan untuk menggambarkan kondisi awal pengguna sebelum menerima rekomendasi. Post-test digunakan untuk melihat kondisi akhir setelah periode intervensi. Apabila nilai post-test lebih rendah dibanding pre-test, maka pengguna mengalami penurunan tingkat stres.

9.2. Uji Statistik yang Digunakan:

Untuk mengevaluasi hasil A/B Testing, digunakan beberapa metode statistik agar hasil tidak hanya dilihat dari perbedaan rata-rata, tetapi juga dari signifikansi dan besar pengaruh intervensi.

Metode	Tujuan
Mann-Whitney U Test	Menguji apakah tingkat stres post-test kelompok treatment lebih rendah secara signifikan dibanding kelompok control
Chi-Square Test	Menguji apakah proporsi pengguna yang turun kategori stres berbeda signifikan antara kelompok kontrol dan treatment
Cohen's d	Mengukur besar pengaruh atau effect size dari perbedaan rata-rata stress_level antar kelompok
Bootstrap 95% CI	Mengestimasi rentang kepercayaan perbedaan rata-rata stress antara kelompok kontrol dan treatment

Hipotesis yang digunakan dalam pengujian ini adalah:

- H_0 : Tidak terdapat perbedaan tingkat stres antara kelompok kontrol dan kelompok treatment.
- H_1 : Kelompok treatment memiliki tingkat stres yang lebih rendah setelah mendapatkan rekomendasi berbasis segmen.

9.3. Hasil Simulasi A/B Test:

Berdasarkan hasil simulasi, kelompok treatment menunjukkan tingkat stres post-test yang lebih rendah dibandingkan kelompok kontrol. Rata-rata stress level pada kelompok kontrol adalah sekitar 7,03, sedangkan kelompok treatment memiliki rata-rata sekitar 5,84. Selisih rata-rata antara kedua kelompok

adalah sekitar 1,19 poin, yang menunjukkan bahwa kelompok treatment mengalami kondisi stres yang lebih rendah setelah intervensi.

Metrik	Nilai
Mean stress post-test (A)	~7.05
Mean stress post-test (B)	~5.84
Perbedaan mean (A-B)	~1.19
Mann-Whitney p-value	< 0.001 (signifikan)
Cohen's d	~0.65 (effect size sedang-besar)
Improve rate (A)	~13.8%
Improve rate (B)	~41%
Chi-Square p-value	< 0.001 (signifikan)

Hasil Mann-Whitney U Test menunjukkan p-value < 0,001, sehingga H_0 ditolak. Artinya, terdapat perbedaan yang signifikan antara tingkat stres kelompok kontrol dan treatment. Kelompok treatment memiliki stress_level post-test yang lebih rendah dibanding kelompok kontrol.

Nilai Cohen's d sekitar 0,65 menunjukkan bahwa perbedaan antara kedua kelompok berada pada kategori effect size sedang. Dengan kata lain, intervensi rekomendasi tidak hanya berbeda secara statistik, tetapi juga memiliki pengaruh yang cukup bermakna secara praktis.

Hasil Bootstrap 95% Confidence Interval menunjukkan bahwa rentang perbedaan rata-rata stress antara kelompok kontrol dan treatment berada pada nilai positif dan tidak melewati nol. Hal ini memperkuat bahwa rata-rata stress kelompok kontrol lebih tinggi dibanding kelompok treatment. Karena interval kepercayaan tidak melewati nol, maka perbedaan tersebut dapat dianggap cukup kuat.

Selain itu, hasil Chi-Square Test menunjukkan p-value < 0,001. Proporsi pengguna yang mengalami penurunan kategori stres pada kelompok treatment mencapai sekitar 41,0%, sedangkan pada kelompok kontrol hanya sekitar 13,8%. Ini menunjukkan bahwa pengguna yang menerima rekomendasi berbasis segmen memiliki peluang lebih besar untuk mengalami perbaikan kategori stress

Kesimpulan: Intervensi rekomendasi berbasis segmen **terbukti** secara statistik **menurunkan tingkat stres pengguna** dengan effect size yang meaningful.

10. Deployment ke Streamlit Cloud

Dashboard di-deploy ke Streamlit Community Cloud agar dapat diakses secara publik tanpa perlu setup server oleh pengguna.

1. Siapkan repository GitHub dengan struktur: dashboard.py, requirements.txt, README.md.
2. Buat file requirements.txt berisi semua dependensi (streamlit, pandas, numpy, matplotlib, seaborn, scipy, scikit-learn).
3. Login ke <https://share.streamlit.io> dengan akun GitHub.
4. Klik 'New app' -> pilih repository, branch, dan file utama (dashboard_streamlit.py).
5. Klik 'Deploy' dan tunggu proses build selesai (~2-5 menit).
6. Dashboard tersedia di URL publik berbentuk: [StressGuard – Deteksi Dini Stres · Streamlit](#)

Isi requirements.txt:

```
streamlit>=1.32.0
pandas>=2.0.0
numpy>=1.26.0
matplotlib>=3.8.0
seaborn>=0.13.0
scipy>=1.12.0
scikit-learn>=1.4.0
```

11. Kesimpulan & Rekomendasi Akhir

11.1 Kesimpulan

- Pola tidur dan penggunaan mobile terbukti dapat digunakan sebagai prediktor tingkat stres yang akurat.
- Mental fatigue score, screen time, dan sleep quality score adalah tiga prediktor terkuat.
- Segmen high_screen_low_sleep_quality menunjukkan high stress rate 100%, menjadikannya prioritas intervensi utama.
- Model baseline Random Forest mencapai akurasi dan F1 macro yang tinggi pada dataset bersih.
- A/B testing membuktikan intervensi rekomendasi berbasis segmen menurunkan stres secara statistik signifikan.
- Dashboard Streamlit berhasil dibangun dan dapat di-deploy sebagai alat monitoring stres berbasis data.

11.2 Rekomendasi Bisnis per Segmen

Segmen	Prioritas	Rekomendasi Utama
high_screen_low_sleep_quality	Kritis	Reminder screen time + sleep hygiene + evaluasi stres harian
high_screen_time	Tinggi	Fitur screen time limit + break reminder + aktivitas non-digital
low_sleep_quality	Sedang	Tips sleep hygiene + reminder jadwal tidur + edukasi sebelum tidur
general_users	Normal	Monitoring ringan + rekomendasi preventif

11.3 Pengembangan Lanjutan

- Tambahkan input `mental_fatigue_score` ke antarmuka aplikasi untuk meningkatkan akurasi model.
- Kembangkan fitur notifikasi push berbasis prediksi stres real-time.
- Perluas dataset dengan data longitudinal pengguna nyata (bukan sintetis dari platform).